

Лабораторная работа IV. Инференс

1 Задание

1.1 Реализовать GQA (5 баллов)

В этом задании вам необходимо реализовать GQA для вашей модели. Адаптируйте конфигурационный файл и механизм внимания (работа с Flash Attention приветствуется).

1.2 Реализовать KV-кэш для инференса (5 баллов)

В этом задании вам необходимо реализовать KV-кэш для инференса вашей модели с GQA.

В случае сильной нехватки памяти, рекомендуется или уменьшить число групп в GQA, или применить такой инструмент как **cpu offloading**.

1.3 Обучить модель (5 баллов)

Обучите вашу модель, оцените метрику перплексии на валидационном датасете.

Если $\text{perplexity} \leq 40$, то за задание ставится 2 балла.

Если $\text{perplexity} \leq 25$, то за задание ставится дополнительно 3 балла.

1.4 Генерация текстов в инференсе (5 баллов)

Подготовьте скрипт для генерации вашей моделью продолжения введенного текста. Работу этого скрипта необходимо будет продемонстрировать на защите.

Подсказка: не забудьте реализовать инициализацию обученной модели из сохраненных весов.